



Identificação e Ofuscação de Vulnerabilidades de Segurança e de Comportamentos na IoT

Fernando Nakayama de Queiroz

Center for Computational Security sScience (CCSC)

Belo Horizonte – Brazil

20 de Janeiro de 2023



www.ccsc-research.org



Trabalhos Seleccionados de AML

Atividades

- 1) Projetar e implementar uma solução para analisar o tráfego das redes IoT em busca de estatísticas;
- 2) Projetar uma interface gráfica para a plataforma CAMALEÃO sendo proposta;
- 3) Modelagem da identificação dos tipos de dispositivos da IoT;
- 4) Propor modelos de aprendizagem de máquina para identificar vulnerabilidades em dispositivos da IoT;
- 5) Criar e divulgar uma base de dados com padrões de comportamento das vulnerabilidades de dispositivos IoT;
- 6) Modelos de AML como princípio para a ofuscação do comportamento dos dispositivos em redes IoT;
- 7) Implantação de um gerenciador de filas para organizar as requisições e instruções recebidas e enviadas pelo Centro de Inteligência;
- 8) Avaliação do funcionamento e desempenho da plataforma CAMALEÃO proposta e compará-la às soluções existentes na literatura;
- 9) Documentar e publicar os resultados do projeto em revistas e conferências especializadas;
- 10) Reuniões periódicas com os colaboradores.

| | 1º Ano | | | | 2º Ano | | | |
|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| | 1º Tri | 2º Tri | 3º Tri | 4º Tri | 1º Tri | 2º Tri | 3º Tri | 4º Tri |
| Atv 1 | ◉ | ◉ | ◉ | | | | | |
| Atv 2 | | ◉ | ◉ | ◉ | ◉ | | | |
| Atv 3 | ◉ | ◉ | ◉ | ◉ | ◉ | ◉ | | |
| Atv 4 | ◉ | ◉ | ◉ | ◉ | ◉ | ◉ | | |
| Atv 5 | | | | ◉ | ◉ | ◉ | | |
| Atv 6 | ◉ | ◉ | ◉ | ◉ | ◉ | ◉ | | |
| Atv 7 | | | ◉ | ◉ | ◉ | | | |
| Atv 8 | ◉ | ◉ | ◉ | ◉ | ◉ | ◉ | ◉ | ◉ |
| Atv 9 | | ◉ | | ◉ | | ◉ | | ◉ |
| Atv 10 | ◉ | | ◉ | | ◉ | | ◉ | |

| | 1º Ano | | | | 2º Ano | | | |
|--------|--------|--------|--|--------|--------|--------|--------|--------|
| | 1º Tri | 2º Tri | 3º Tri | 4º Tri | 1º Tri | 2º Tri | 3º Tri | 4º Tri |
| Atv 1 | ● | ✓ | Projetar e implementar uma solução para analisar o tráfego das redes IoT em busca de estatísticas; | | | | | |
| Atv 2 | | ● | ● | ● | ● | | | |
| Atv 3 | ● | ✓ | Modelagem da identificação dos tipos de dispositivos da IoT; | | | | | |
| Atv 4 | ● | ✓ | Propor modelos de aprendizagem de máquina para identificar vulnerabilidades em dispositivos da IoT; | | | | | |
| Atv 5 | | | | ● | ● | ● | | |
| Atv 6 | ● | ? | Modelos de AML como princípio para a ofuscação do comportamento dos dispositivos em redes IoT; | | | | | |
| Atv 7 | | | ● | ● | ● | | | |
| Atv 8 | ● | ? | Avaliação do funcionamento e desempenho da plataforma CAMALEÃO proposta e compará-la às soluções existentes na literatura; | | | | | |
| Atv 9 | | ● | | ● | | ● | | ● |
| Atv 10 | ● | ✓ | Reuniões periódicas com os colaboradores. | | | | | |

| | 1º Ano | | | | 2º Ano | | | |
|--------|--------|--------|--|--------|--------|--------|--------|--------|
| | 1º Tri | 2º Tri | 3º Tri | 4º Tri | 1º Tri | 2º Tri | 3º Tri | 4º Tri |
| Atv 1 | ● | ● | ● | | | | | |
| Atv 2 | | ● | Projetar uma interface gráfica para a plataforma CAMALEÃO; | | | | | |
| Atv 3 | ● | ● | ● | ● | ● | ● | | |
| Atv 4 | ● | ● | ● | ● | ● | ● | | |
| Atv 5 | | | | ● | ● | ● | | |
| Atv 6 | ● | ● | ● | ● | ● | ● | | |
| Atv 7 | | | ● | ● | ● | | | |
| Atv 8 | ● | ● | ● | ● | ● | ● | ● | ● |
| Atv 9 | | ● | Documentar e publicar os resultados do projeto; | | | | | |
| Atv 10 | ● | | ● | | ● | | ● | 6 |

Behaviour source analysis

1- Projetar e implementar uma solução para analisar o tráfego das redes IoT em busca de estatísticas



Packet header statistics

Network flow statistics

Combined methods

Externally collected
Universality
Multiple devices (per gateway)
Impersonation
Encrypted data



Clock drift (skewness)

RAW quadrature signals

Signal frequency

Externally/internally-collected
Instance identification
Difficulty of tampering
Comprise composed solutions
Complex data gathering

Estado da arte - Origem dos dados

1- Projetar e implementar uma solução para analisar o tráfego das redes IoT em busca de estatísticas



Estatística cabeçalhos

Estatística fluxos

Métodos combinados

Coletados internamente e externamente

Compatibilidade

Múltiplos dispositivos por gateway

Imitação/clonagem de dispositivos

Dados criptografados



Variação do relógio

Sinais de quadratura

Frequência dos sinais

Coletados internamente e externamente

Identificação de instâncias

Dificuldade de adulteração

Soluções compostas e complexas

Dificuldade na coleta de dados

Estado da arte - Categorias de identificação

3- Modelagem da identificação dos tipos de dispositivos da IoT

Tipos de dispositivo

Classificação de um ou mais dispositivos IoT

Instâncias

Classificação de uma instância específica

Comportamento Anômalo

Detecção invasão / ataques

Estado da arte - Modelos de AM

4- Propor modelos de aprendizagem de máquina para identificar vulnerabilidades em dispositivos da IoT

Tipos de dispositivo

Objetivos:
Classificação

Datasets:
Públicos
Privados

Instâncias

Objetivos:
Classificação
Análise de dados

Datasets:
Privados

Comportamento Anômalo

Objetivos:
Classificação
Detecção de anomalias

Datasets:
Públicos
Privados

Estado da arte - Modelos de AM

4- Propor modelos de aprendizagem de máquina para identificar vulnerabilidades em dispositivos da IoT

Tipos de dispositivo

Técnicas/Algoritmos:

Redes neurais, Naive bayes, Random forest, Gradient boosting, k-NN, Árvores de decisão, Multilayer perceptron, t-SNE, DBSCAN, C-means, CNN (variações), máquinas de estados, interpolação

Instâncias

Técnicas/Algoritmos:

Estatística, Redes neurais, LSTM, Árvores de decisão

Comportamento Anômalo

Técnicas/Algoritmos:

Mesmas anteriores + modelos lineares, IQR (Interquartile range), Autoregressão

Estado da arte - Modelos de AM

4- Propor modelos de aprendizagem de máquina para identificar vulnerabilidades em dispositivos da IoT

Tipos de dispositivo

Origem:

Rede

Sinais de rádio

Características:

Cabeçalho, intervalo de resposta, estatística dos fluxos, estatística da sequência dos pacotes, análise do DNS, amostras de sinais de quadratura

Instâncias

Origem:

Rede

Processadores

Osciladores

Relógio

Sinais eletromagnéticos

Características:

Voltagem, beacon Wi-Fi, uso da UCP, amostras de sinais eletromagnéticos

Comportamento Anômalo

Origem:

Rede

Sensores

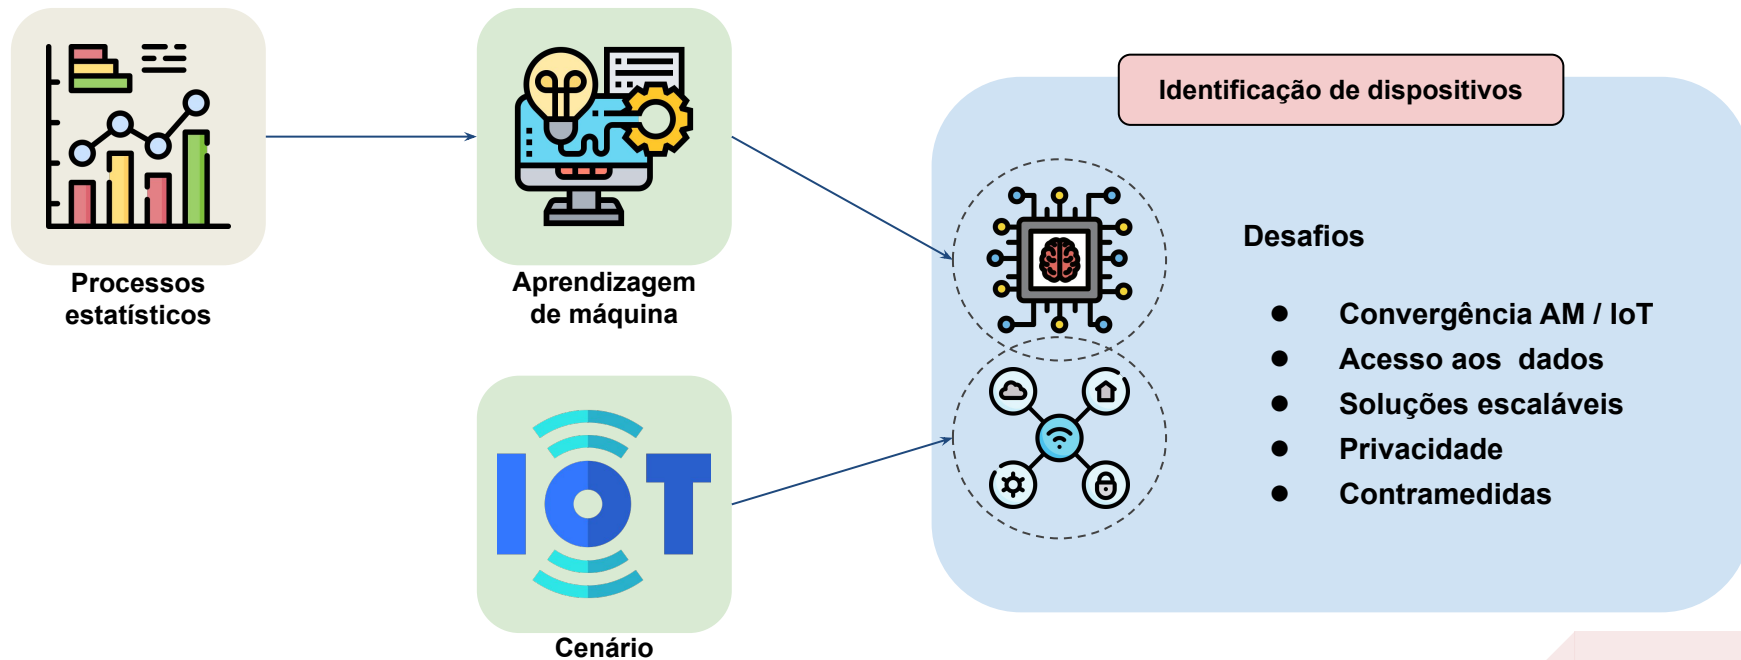
Chamadas de sistema

Logs

Características:

Cabeçalho, estatística dos fluxos, valores de sensores, valores da UCP, registros de hardware, registros de sistema

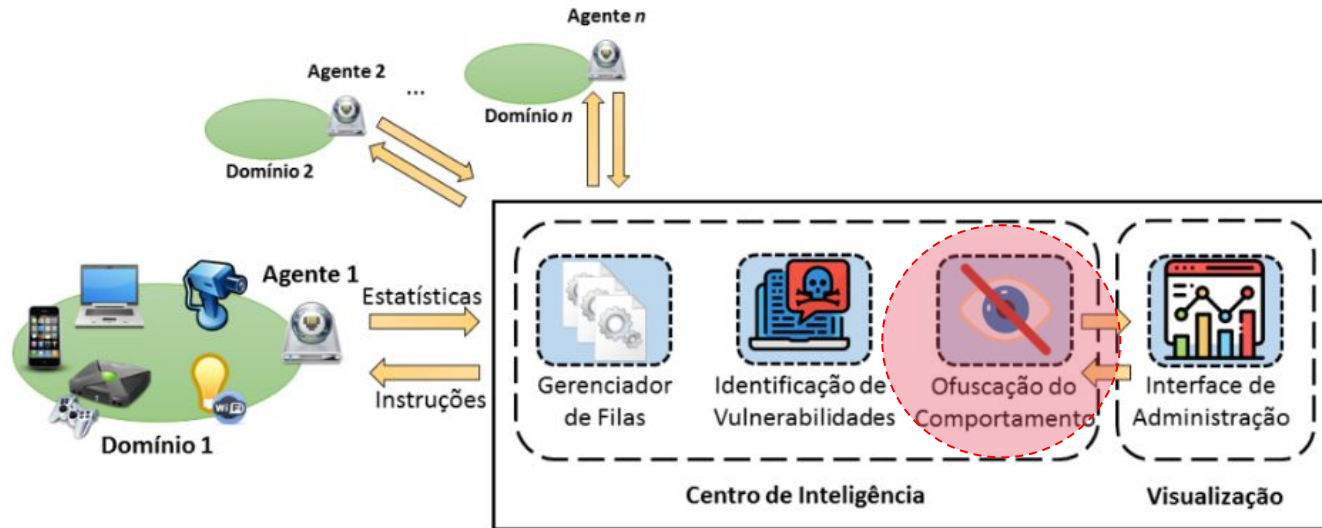
Desafios



Aprendizado de Máquina Adversário - AML (Adversarial Machine Learning)

“O aprendizado de máquina adversário é uma técnica usada no aprendizado de máquina para enganar ou desorientar um modelo através de uma entrada de dados maliciosa”

Aprendizado de Máquina Adversário - AML (Adversarial Machine Learning)



Aprendizado de Máquina Adversário - AML (Adversarial Machine Learning)



x

“panda”
57.7% confidence

$+ .007 \times$




$=$



$x +$
 $\epsilon \text{sign}(\nabla_x J(\theta, x, y))$
“gibbon”
99.3 % confidence

Aprendizado de Máquina Adversário - AML (Adversarial Machine Learning)



Aprendizado de Máquina Adversário - AML (Adversarial Machine Learning)

Algorithm 3 Adversarial Burst

Input Flow set F of class l , flow content classifier f_{1D-CNN} with weights θ , selected burst indices vector IND_{SBurst} , number of dummy packets $Num_of_dummy_pkts$, perturbation rate ϵ , number of iterations T , batch size $batch_size$.

Output UAP ξ

```

1:  $\xi \leftarrow Rand(Domain(F), Size = Num\_of\_dummy\_pkts)$ 
2: for  $t \leftarrow 0, T$  do
3:    $F^{batch} \leftarrow sample\ batch\_size\ flows\ from\ F$ 
4:    $IND^{batch} \leftarrow selected\ burst\ index\ of\ F^{batch}\ in\ IND_{SBurst}$ 
5:   for  $i \leftarrow 0, batch\_size$  do
6:      $flows\_time\_series_i^{batch} \leftarrow flow\_to\_burst\_seq(F_i^{batch})$ 
7:      $Brs_i^i = flows\_time\_series_i^{batch}[IND_i^{batch}]$ 
8:      $Brs_{adv}^i = append(Brs_i^i, \xi)$ 
9:      $flows\_time\_series_i^{batch}[IND_i^{batch}] = Brs_{adv}^i$ 
10:  end for
11:   $\Delta\xi = \epsilon \times \nabla_{\xi} J(\theta, flows\_time\_series^{batch}, l)$ 
12:   $\xi = Clip_{Domain(F)}(\xi + \Delta\xi)$ 
13: end for
14: return  $\xi$ 

```

- 1- Adversarial PAD
- 2- Adversarial Payload
- 3- Adversarial Burst

FTSC-IAT

| Attack | Attack Parameter | Overall Accuracy(%) | Recall(%) | | | | | |
|-----------|------------------|---------------------|-----------|-------|---------------|-----------|---------|-------|
| | | | Chat | Email | File Transfer | Streaming | Torrent | VoIP |
| No Attack | | 69.62 | 34.95 | 75.95 | 73.76 | 66.51 | 85.00 | 73.95 |
| AdvBurst | 7 dummy pkts | 31.31 | 5.83 | 37.97 | 19.50 | 81.65 | 3.75 | 20.58 |

Identificação de dispositivos IoT

- 8 trabalhos (2 revisões)

AML

- 8 trabalhos (1 revisão)